

Maestría de Ciencia de Datos e Inteligencia Artificial

Big Data

2.5 CRÉDITOS

ÍNDICE

1. DATOS GENERALES
2. SUMILLA
3. OBJETIVOS
4. COMPETENCIAS Y RESULTADOS DE APRENDIZAJE
5. TEMAS
6. METODOLOGÍA
7. SISTEMA DE EVALUACIÓN
8. REFERENCIAS BIBLIOGRÁFICAS

SILABO 2025-2

1. DATOS GENERALES

CURSO	CS8087 - Big Data						
CICLO	5	**CRÉDITOS**	2.5	**HT**	20	**HL**	40
DURACIÓN DEL PERIODO	15 semanas	**TIPO DEL CURSO**	Obligatorio				
MODALIDAD	Híbrido	**REQUISITOS**	CS8079 - Machine Learning CS8083 - Data Engineering				

2. INTRODUCCIÓN AL CURSO

El curso de Big data es de naturaleza teórica-práctico y tiene como objetivo que los estudiantes analicen los fundamentos del big data haciendo uso del pensamiento crítico, mediante la resolución de casos y los recursos disponibles. Los principales contenidos que se desarrollarán son: los fundamentos del big data, volumen, variedad, velocidad y veracidad de los datos; las arquitecturas de sistemas de big data, como Hadoop y Spark, y se introducirán técnicas y herramientas para el procesamiento y almacenamiento distribuido de datos, entre otros temas.

3. OBJETIVOS

Objetivo 1:
Desarrollar la capacidad de analizar, diseñar e implementar soluciones de Big Data, integrando fundamentos teóricos, arquitecturas modernas y marcos de procesamiento distribuido para abordar retos empresariales complejos en entornos de datos masivos y heterogéneos.

Objetivo 2:
Fomentar el pensamiento crítico y estratégico en la gestión del ciclo de vida de los datos, promoviendo el uso ético, seguro y responsable de herramientas y prácticas de gobierno de datos, calidad, DataOps y MLOps en escenarios reales y simulados.

4. COMPETENCIAS Y RESULTADOS DE APRENDIZAJE

Cód.	Competencia	Cód.	Resultados de aprendizaje
CD01	Analiza y evalúa de manera crítica los problemas y desafíos relacionados con su área de especialización, identificando supuestos, evidencias, implicaciones y posibles soluciones y aplicando enfoques de pensamiento crítico para tomar decisiones fundamentadas y resolver problemas complejos (nivel 5)	RA1	Analizar y evaluar arquitecturas y sistemas de Big Data para procesar grandes volúmenes de datos en entornos distribuidos.
CD02	Genera ideas originales, propone soluciones novedosas y fomenta la creatividad en el ámbito de la gestión de su especialización (nivel 5)	RA2	Diseñar e implementar soluciones de Big Data utilizando herramientas modernas como Hadoop y Spark.
CD03	Planifica, organiza y controla proyectos, teniendo en cuenta los recursos disponibles, los plazos establecidos y los resultados esperados (nivel 5)	RA3	Optimizar procesos de análisis y almacenamiento de datos para garantizar eficiencia, escalabilidad y precisión.
CD04	Identifica, formula y resuelve problemas de manera innovadora, utilizando enfoques basados en datos y evidencia computacional (nivel 5)	RA4	Planificar y gestionar proyectos de Big Data asegurando el cumplimiento de principios éticos y de seguridad.

5. TEMAS

Unidad 1: Fundamentos, Estrategia y Almacenamiento Distribuido

1. **Teoría Académica**: Definición, importancia y alineamiento con la estrategia de negocio. Diferencias entre Big Data y datos tradicionales.
2. **Sistemas de Big Data**: El ecosistema Hadoop (HDFS, MapReduce y YARN).
3. **Implementación en GCP:**
   3.1. Migración de HDFS a Cloud Storage y BigQuery Storage.
   3.2. Gestión de clusters Spark/Hadoop gestionados con Cloud Dataproc.
   3.3. Uso de Big Lake como motor de almacenamiento unificado para Iceberg/Delta.
4. **Workshop Práctico:** Despliegue de un Data Lakehouse distribuido y auditoría de toma de decisiones empresariales basada en datos.

Unidad 2: Arquitectura de Datos y Procesamiento Moderno

1. **Teoría Académica**: Introducción a arquitecturas de datos y patrones de implementación. Marcos de procesamiento distribuido (Hadoop y Spark).
2. **Calidad y DataOps:** Marcos de calidad de datos y flujo de DataOps.
3. **Implementación en GCP:**
   3.1. Cloud Dataflow (Apache Beam): Procesamiento unificado de Batch y Streaming.
   3.2. Dataform: Transformación de datos masivos mediante SQLX (DataOps en la nube).
   3.3. Pub/Sub: Ingesta de eventos a escala global para velocidad de datos.
4. **Workshop Práctico:** Construcción de un pipeline ETL distribuido con validación automática de calidad.

Unidad 3: Arquitecturas ML/IA y la Era Agéntica

- **Teoría Académica**: Introducción a MLOps. Implementación de RAG (Retrieval-Augmented Generation) y Prompting para Data Management.
- **La Era Agéntica:** Conceptos y evolución hacia agentes inteligentes.
- **Despliegue de Modelos en GCP:**
  - Vertex AI: Entrenamiento y despliegue de modelos fundacionales.
  - BigQuery Gemini Pro: Ejecución de modelos LLM (Gemini) directamente en SQL para análisis masivo.
  - Agent Engine SDK: Programación de agentes que razonan sobre Big Data.
  - Document AI: Extracción de datos de documentos no estructurados para alimentar modelos.
- **Workshop Práctico**: Despliegue de un Agente de IA que consulta el Data Warehouse y genera respuestas contextuales mediante RAG.

Unidad 4: Gobierno, Ética y Orquestación

1. **Teoría Académica:** Principios de Gobierno de Datos, roles y responsabilidades. Ética, Privacidad y Seguridad de Datos.
2. **Implementación en GCP:**
   2.1. Cloud Composer (Apache Airflow): Orquestación de flujos de trabajo complejos de Big Data y ML.
   2.2. Dataplex: Herramienta de implementación para gobierno de datos, linaje y seguridad centralizada.
   2.3. Cloud Run: Despliegue de microservicios para interactuar con la arquitectura agéntica.

Unidad 5: Workshop Práctico:

1. Automatización de un ciclo de vida completo de datos (Ingesta -> Proc -> ML -> Agente) asegurando principios éticos.

6. METODOLOGÍA

En el curso de Big Data, se aplicará la metodología de Aprendizaje Basado en Proyectos (ABP) para fortalecer el desarrollo de competencias prácticas en contextos reales. A través del ABP, los estudiantes planificarán, gestionarán y ejecutarán proyectos vinculados a la ciencia de datos e inteligencia artificial, enfrentando desafíos concretos como la implementación de iniciativas de analítica avanzada, la gestión de proyectos de transformación digital o la coordinación de equipos multidisciplinarios en entornos tecnológicos. Esta metodología fomenta la autonomía, el liderazgo, la gestión de la incertidumbre, el análisis crítico y la innovación, competencias esenciales para profesionales de posgrado en ciencia de datos y tecnología aplicada, en alineación con el modelo educativo de posgrado de UTEC.

Esta metodología se centra en la ejecución de un **Proyecto Integrador de Arquitectura Agéntica**, donde el estudiante asume el rol de *Principal Data Architect*. El curso se divide en tres capas de aprendizaje:

1. El Reto de Gestión y Planificación

- **Gestión de la Incertidumbre:** Se presentarán datasets "sucios" y masivos (logs reales, documentos PDF sin estructura) donde el alumno deberá decidir el stack óptimo (ej: ¿Dataproc para legacy o Dataflow para modernización?).
- **Alineamiento con OKRs:** Cada decisión técnica en GCP deberá estar justificada por un impacto en el negocio, simulando una transformación digital real.

2. Ejecución Técnica con "Modern Data Stack" (GCP)

La parte práctica se desarrolla mediante **Sprints Técnicos** donde los estudiantes aplicarán:

- **Arquitecturas de Procesamiento Distribuido:** Implementación real de clusters de Hadoop/Spark en **Dataproc** y pipelines serverless en **Dataflow**.
- **Despliegue de IA y Era Agéntica:** Los estudiantes no solo entrenan modelos, sino que deberán **desplegar agentes inteligentes** utilizando el **Agent Engine SDK**, integrando búsqueda vectorial y RAG para resolver el desafío planteado.
- **DataOps y Automatización:** Uso de **Dataform** y **Cloud Composer** para gestionar el ciclo de vida de los datos, fomentando la autonomía en la coordinación de flujos tecnológicos complejos.

3. Dinámica de Trabajo en el Aula

- **Semanas 1-4 (Cimentación):** Workshops intensivos de arquitectura y almacenamiento masivo. El alumno planifica su infraestructura en GCP.
- **Semanas 5-10 (Construcción):** Ejecución de pipelines de datos masivos. Aquí se enfrenta la gestión de desafíos concretos como la latencia y el costo de cómputo.
- **Semanas 11-15 (Inteligencia y Orquestación):** Los estudiantes integran la capa de **AI Agents** y orquestan todo el sistema, demostrando liderazgo técnico e innovación.

7. SISTEMA DE EVALUACIÓN

DETALLE	CALIFICACIÓN
Evaluación - Caso de Estudio: Diseño de la arquitectura Big Data y alineamiento estratégico **(E1)**	25%
Proyecto 1 (Entregable I): Implementación del pipeline de ingesta y procesamiento distribuido (Dataflow/Spark) **(P1)**	25%
Proyecto 2 (Entregable II): Despliegue del modelo de IA/ML y arquitectura RAG en Vertex AI. **(P2)**	25%
Proyecto 3 (Entregable III): Entrega final del **Agente Inteligente** orquestado y gobernado. **(P3)**	25%
TOTAL	**100%**

8. REFERENCIAS BIBLIOGRÁFICAS

- Mike Rollings & Andrew White (2018). Build a Data-Driven Enterprise. Gartner.

Recuperado de:
https://www.gartner.com/smarterwithgartner/build-a-data-driven-organization

- John Doerr (2018). Measure What Matters: How Google, Bono, and the Gates Foundation Rock the World with OKRs (1st ed.). Portfolio.

- Hilary Mason & DJ Patil (2015). Data Driven: Creating a Data Culture (1st ed.). O'Reilly Media, Inc. Recuperado de: https://www.oreilly.com/library/view/data-driven/9781491925454/

- Ted Malaska & Jonathan Seidman (2018). Foundations for Architecting Data Solutions (1st ed.). O'Reilly Media, Inc.

- Pethuru Raj, Anupama Raman & Harihara Subramanian (2017). Architectural Patterns (1st ed.). Packt Publishing.

- Richard Lawrence & Paul Rayner (2017). Behavior Driven Development with Cucumber: Better Collaboration for Better Software (1st ed.). Addison-Wesley.

- Google. Guía de arquitectura de aplicaciones de Google Cloud. Recuperado de: https://cloud.google.com/architecture?hl=es-419